ACTIVIDAD 2

David Valcárcel Herrera

Índice de la actividad 3

1 Objetivo **1**

2 Código **2**
2.1 Preprocesamiento de datos 2
2.2 GLMs con diferentes distribuciones 5
2.3 Comparaciones post-hoc y letras de significación 9
2.4 Visualización final 11

3 Conclusiones de la actividad **12**
3.1 En cuanto a las conclusiones del modelo utillizado (el mejor de todos los probados) 12
3.2 En cuanto a las conclusiones sobre el conteo de insectos (del boxplot) 13

1. Objetivo

En esta segunda actividad propuesta trabajamos con un conjunto de datos de capturas de insectos aplicando distintos tratamientos A y B y una mezcla de los dos.
Nuestro flujo de trabajo consiste en:

1. **Carga de datos y exploración inicial.**
   - Leemos los datos desde un Excel e inspeccionamos su estructura.
2. **ANOVA clásico.**
   - Probamos normalidad y homogeneidad de varianzas.
   - Aplicamos transformaciones Box-Cox si es necesario.
3. **Modelos GLM.**
   - Ajustamos modelos con distribuciones *gaussian*, *poisson*, *binomial negativa*, *beta* y *gamma*.
   - Comparamos mediante diagnóstico de residuos (DHARMa).
4. **Selección del mejor modelo.**
   - El modelo con distribución binomial negativa se ajusta mejor a los datos.
5. **Comparaciones post-hoc.**
   - Usamos `glht` y `emmeans` para contrastes de Tukey y obtenemos letras de significación.
6. **Visualización.**

- Generamos boxplots con las letras de comparación entre tratamientos.

---

2. Código

2.1. Preprocesamiento de datos

```
# Instalación y carga de librerías
if(!require("readxl")) install.packages("readxl")
```

```
Cargando paquete requerido: readxl
```

```
if(!require("pwr")) install.packages("pwr")
```

```
Cargando paquete requerido: pwr
```

```
Warning: package 'pwr' was built under R version 4.4.3
```

```
if(!require("car")) install.packages("car")
```

```
Cargando paquete requerido: car
```

```
Cargando paquete requerido: carData
```

```
if(!require("MASS")) install.packages("MASS")
```

```
Cargando paquete requerido: MASS
```

```
Warning: package 'MASS' was built under R version 4.4.3
```

```
library(readxl)
library(pwr)
library(car)
library(MASS)

# Lectura de datos
insectos = read_xlsx("C:/Users/dvalh/Desktop/UA/MatesUA/Prácticas de empresa + privado/Activ
summary(insectos)
```

```
 Tratamiento           Replica         Conteo
 Length:40          Min.   : 1.0   Min.   :  0.00
 Class :character   1st Qu.: 3.0   1st Qu.: 11.75
 Mode  :character   Median : 5.5   Median : 26.50
                    Mean   : 5.5   Mean   : 44.70
                    3rd Qu.: 8.0   3rd Qu.: 55.25
                    Max.   :10.0   Max.   :292.00
```

```
#ANOVA clásico
pwr.anova.test(k = 4, n = NULL, f = 0.4, sig.level = 0.05, power = 0.8)
```

```
     Balanced one-way analysis of variance power calculation

              k = 4
              n = 18.04262
              f = 0.4
      sig.level = 0.05
          power = 0.8

NOTE: n is number in each group
```

```
#n = 15

insectos$Tratamiento = as.factor(insectos$Tratamiento)

modelo_aovtr = aov(Conteo ~ Tratamiento, data = insectos)
summary(modelo_aovtr)
```

```
             Df Sum Sq Mean Sq F value Pr(>F)
Tratamiento   3  18256    6085   2.199  0.105
Residuals    36  99609    2767
```

```
# Normalidad y homogeneidad
shapiro.test(resid(modelo_aovtr))
```

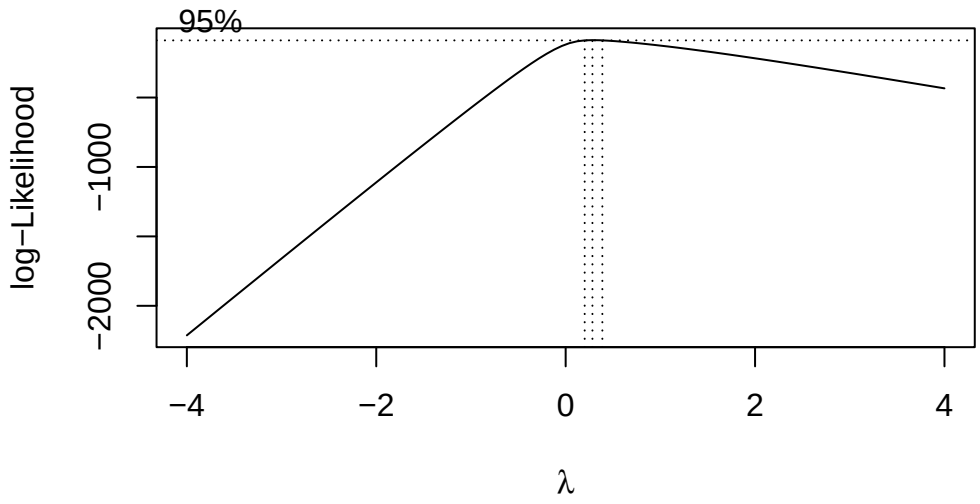
```
    Shapiro-Wilk normality test

data:  resid(modelo_aovtr)
W = 0.75571, p-value = 9.121e-07
```

```
leveneTest(Conteo ~ Tratamiento, data = insectos)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  3  1.0685 0.3746
      36
```

```r
# Transformación Box-Cox
insectos$Conteo_mod = insectos$Conteo + 0.00001
boxcox_result <- boxcox(insectos$Conteo_mod ~ insectos$Tratamiento, lambda = seq(-4, 4, 0.1)
```




```r
lambda_optimo <- boxcox_result$x[which.max(boxcox_result$y)]

if(abs(lambda_optimo) < 0.01) {
  insectos$conteo_trans <- log(insectos$Conteo_mod + 1)
} else {
  insectos$conteo_trans <- ((insectos$Conteo_mod + 1)^lambda_optimo - 1)/lambda_optimo
}

modelo_aov_box <- aov(conteo_trans ~ Tratamiento, data = insectos)
summary(modelo_aov_box)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
Tratamiento  3  93.75  31.248   4.427 0.0095 **
Residuals   36 254.14   7.059
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
shapiro.test(resid(modelo_aov_box))
```

```
    Shapiro-Wilk normality test

data:  resid(modelo_aov_box)
W = 0.96634, p-value = 0.274
```

```r
leveneTest(conteo_trans ~ Tratamiento, data = insectos)
```

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  3  0.1369 0.9373
      36
```

2.2. GLMs con diferentes distribuciones

```r
if(!require("DHARMa")) install.packages("DHARMa")
```

```
Cargando paquete requerido: DHARMa

Warning: package 'DHARMa' was built under R version 4.4.3

This is DHARMa 0.4.7. For overview type '?DHARMa'. For recent changes, type news(package = '
```

```r
library(DHARMa)

# Reordenar niveles (Control como referencia)
insectos$Tratamiento <- factor(insectos$Tratamiento,
                               levels = c("Control", "A", "B", "A+B"))

# Gaussian
modelo_glm1 <- glm(Conteo ~ Tratamiento, family = gaussian(link = "identity"), data = insect
summary(modelo_glm1)
```

```
Call:
glm(formula = Conteo ~ Tratamiento, family = gaussian(link = "identity"),
    data = insectos)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      66.40      16.63   3.992 0.000309 ***
TratamientoA    -33.50      23.52  -1.424 0.163036
TratamientoB     -2.50      23.52  -0.106 0.915955
TratamientoA+B   -50.80      23.52  -2.159 0.037550 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for gaussian family taken to be 2766.906)

    Null deviance: 117864  on 39  degrees of freedom
Residual deviance:  99609  on 36  degrees of freedom
AIC: 436.32

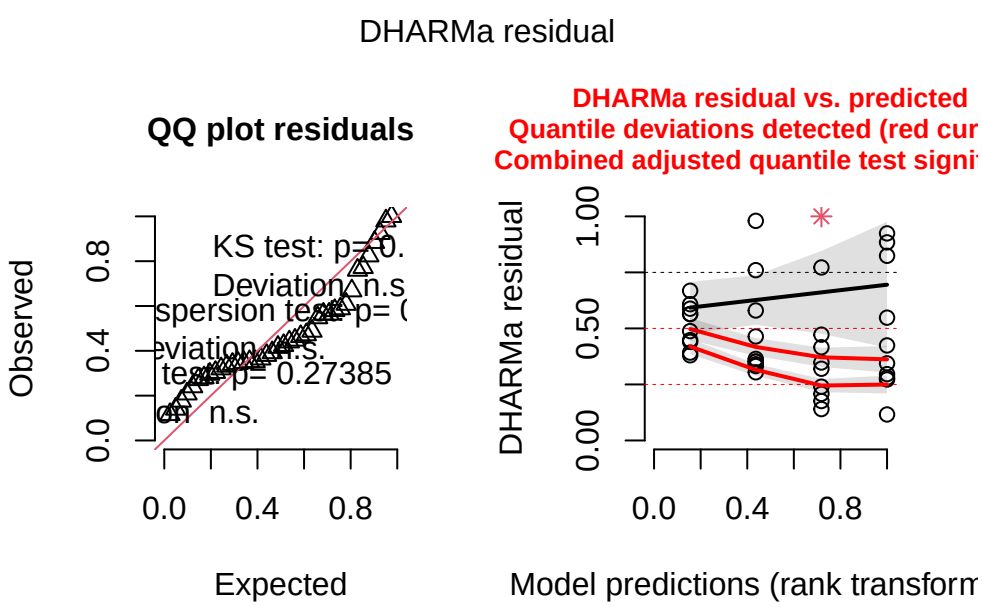
Number of Fisher Scoring iterations: 2
```

```
Anova(modelo_glm1)
```

```
Analysis of Deviance Table (Type II tests)

Response: Conteo
            LR Chisq Df Pr(>Chisq)
Tratamiento   6.5979  3    0.08588 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
plot(simulateResiduals(modelo_glm1))
```




```
# Poisson
modelo_glm2 <- glm(Conteo ~ Tratamiento, family = poisson(link = "log"), data = insectos)
summary(modelo_glm2)
```

```
Call:
glm(formula = Conteo ~ Tratamiento, family = poisson(link = "log"),
    data = insectos)

Coefficients:
               Estimate Std. Error z value Pr(>|z|)
(Intercept)     4.19570    0.03881 108.116   <2e-16 ***
TratamientoA   -0.70222    0.06742 -10.416   <2e-16 ***
TratamientoB   -0.03838    0.05542  -0.693    0.489
TratamientoA+B -1.44843    0.08897 -16.279   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 1904.3  on 39  degrees of freedom
Residual deviance: 1452.2  on 36  degrees of freedom
AIC: 1657.6

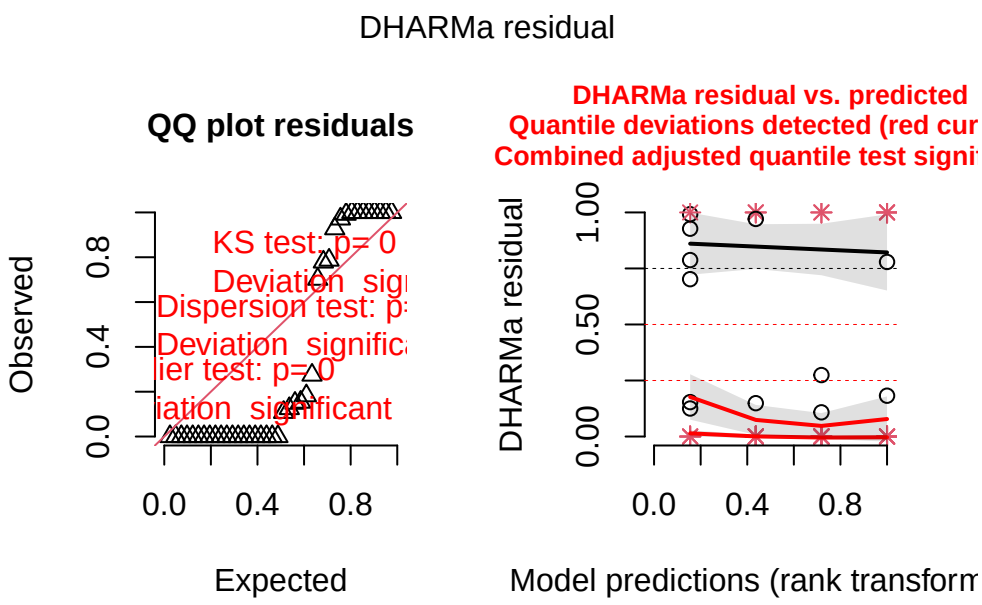
Number of Fisher Scoring iterations: 5
```

```r
Anova(modelo_glm2)
```

```
Analysis of Deviance Table (Type II tests)

Response: Conteo
            LR Chisq Df Pr(>Chisq)
Tratamiento   452.09  3  < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
plot(simulateResiduals(modelo_glm2))
```




```r
# Binomial negativa (mejor ajuste)
modelo_glmnb <- glm.nb(Conteo ~ Tratamiento, data = insectos)
summary(modelo_glmnb)
```

```
Call:
glm.nb(formula = Conteo ~ Tratamiento, data = insectos, init.theta = 1.166866553,
    link = log)

Coefficients:
```

```
               Estimate Std. Error z value Pr(>|z|)
(Intercept)     4.19570    0.29531  14.208  < 2e-16 ***
TratamientoA   -0.70222    0.41946  -1.674 0.094106 .
TratamientoB   -0.03838    0.41770  -0.092 0.926794
TratamientoA+B -1.44843    0.42346  -3.420 0.000625 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.1669) family taken to be 1)

    Null deviance: 60.235  on 39  degrees of freedom
Residual deviance: 46.558  on 36  degrees of freedom
AIC: 382.64

Number of Fisher Scoring iterations: 1

              Theta:  1.167
          Std. Err.:  0.258

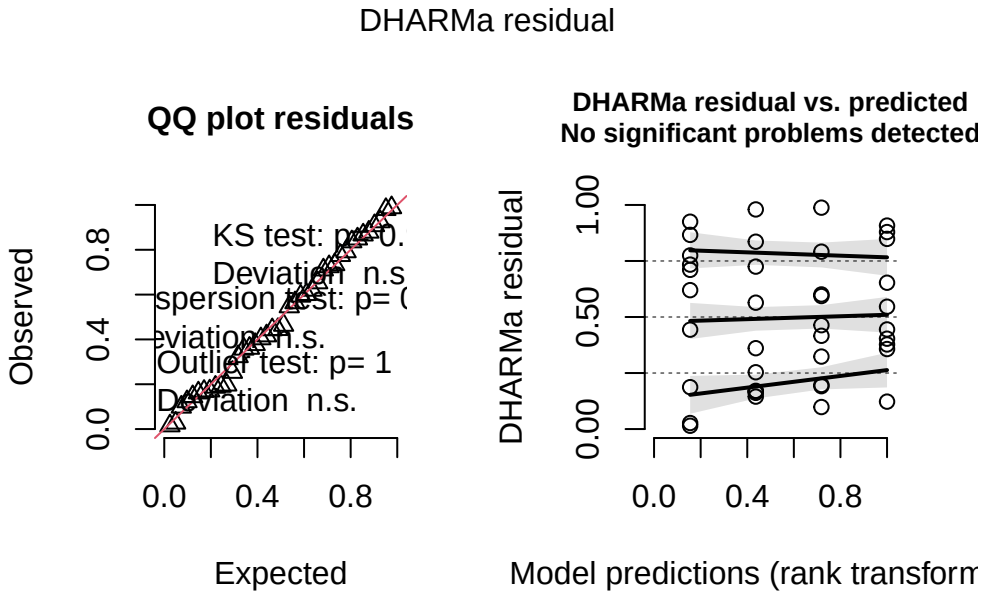
 2 x log-likelihood:  -372.636
```

```
Anova(modelo_glmnb)
```

```
Analysis of Deviance Table (Type II tests)

Response: Conteo
            LR Chisq Df Pr(>Chisq)
Tratamiento   13.677  3    0.00338 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
plot(simulateResiduals(modelo_glmnb))
```



2.3. Comparaciones post-hoc y letras de significación

```
if(!require("multcomp")) install.packages("multcomp")
```

```
Cargando paquete requerido: multcomp
```

```
Cargando paquete requerido: mvtnorm
```

```
Cargando paquete requerido: survival
```

```
Cargando paquete requerido: TH.data
```

```
Adjuntando el paquete: 'TH.data'
```

```
The following object is masked from 'package:MASS':

    geyser
```

```
if(!require("emmeans")) install.packages("emmeans")
```

```
Cargando paquete requerido: emmeans
```

```
if(!require("multcompView")) install.packages("multcompView")
```

```
Cargando paquete requerido: multcompView
```

```
Warning: package 'multcompView' was built under R version 4.4.3
```

```
library(multcomp)
library(emmeans)
library(multcompView)

# Tukey post-hoc
posthoc <- glht(modelo_glmnb, linfct = mcp(Tratamiento = "Tukey"))
summary(posthoc)
```

```
     Simultaneous Tests for General Linear Hypotheses

Multiple Comparisons of Means: Tukey Contrasts


Fit: glm.nb(formula = Conteo ~ Tratamiento, data = insectos, init.theta = 1.166866553,
    link = log)
```

```
Linear Hypotheses:
                    Estimate Std. Error z value Pr(>|z|)
A - Control == 0   -0.70222    0.41946  -1.674  0.33748
B - Control == 0   -0.03838    0.41770  -0.092  0.99972
A+B - Control == 0 -1.44843    0.42346  -3.420  0.00348 **
B - A == 0          0.66385    0.41953   1.582  0.38867
A+B - A == 0       -0.74620    0.42526  -1.755  0.29544
A+B - B == 0       -1.41005    0.42353  -3.329  0.00479 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Adjusted p values reported -- single-step method)
```

```r
plot(posthoc)
```




```r
# emmeans + letras
emmeans_trat <- emmeans(modelo_glmnb, ~ Tratamiento)
```

```r
cld(emmeans_trat, Letters = letters, adjust = "tukey")
```

```
Note: adjust = "tukey" was changed to "sidak"
because "tukey" is only appropriate for one set of pairwise comparisons

 Tratamiento emmean    SE  df asymp.LCL asymp.UCL .group
 A+B           2.75 0.303 Inf      1.99      3.50  a
 A             3.49 0.298 Inf      2.75      4.24  ab
 B             4.16 0.295 Inf      3.42      4.89   b
 Control       4.20 0.295 Inf      3.46      4.93   b

Results are given on the log (not the response) scale.
```

```
Confidence level used: 0.95
Conf-level adjustment: sidak method for 4 estimates
P value adjustment: tukey method for comparing a family of 4 estimates
significance level used: alpha = 0.05
NOTE: If two or more means share the same grouping symbol,
      then we cannot show them to be different.
      But we also did not show them to be the same.
```

2.4. Visualización final

```r
if(!require("ggplot2")) install.packages("ggplot2")
```

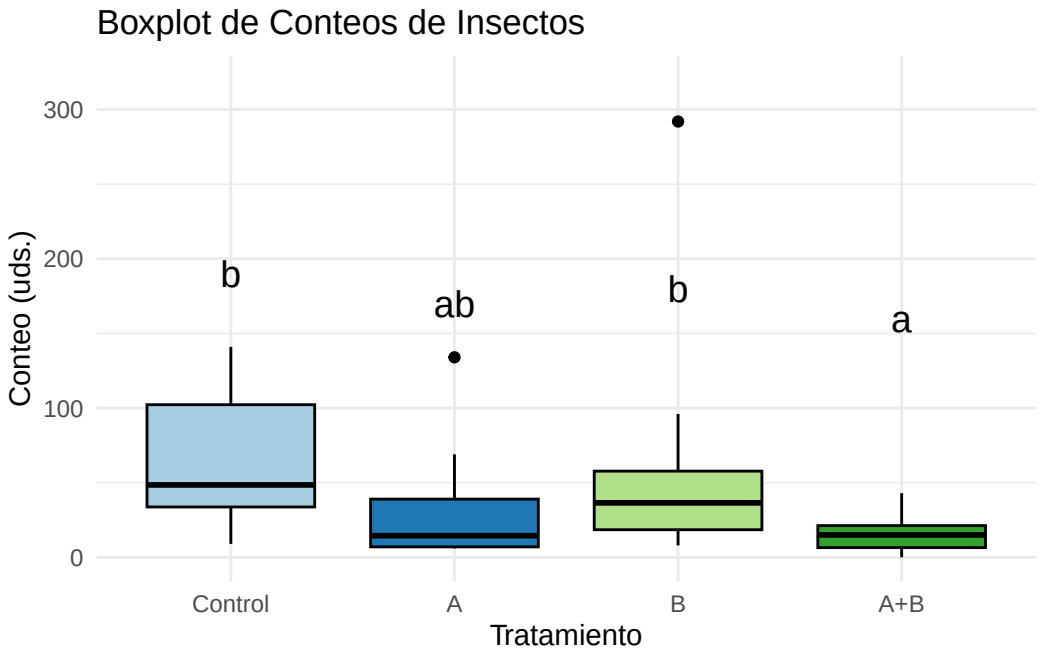
```
Cargando paquete requerido: ggplot2
```

```
Warning: package 'ggplot2' was built under R version 4.4.3
```

```r
library(ggplot2)

pos_letras <- data.frame(
  Tratamiento = factor(c("A+B", "A", "B", "Control"), levels = c("Control", "A", "B", "A+B")
  ypos = c(280, 290, 300, 310),
  Letters = c("a", "ab", "b", "b")
)

ggplot(insectos, aes(x = Tratamiento, y = Conteo, fill = Tratamiento)) +
  geom_boxplot(color = "black") +
  scale_y_continuous(limits = c(0, 320)) +
  scale_x_discrete(labels = c("Control", "A", "B", "A+B")) +
  scale_fill_manual(values = c("#A6CEE3", "#1F78B4", "#B2DF8A", "#33A02C")) +
  labs(title = "Boxplot de Conteos de Insectos", x = "Tratamiento", y = "Conteo (uds.)") +
  geom_text(data = pos_letras, aes(x = Tratamiento, y = ypos-120, label = Letters), size = 5
  theme_minimal() +
  theme(legend.position = "none")
```



3. Conclusiones de la actividad

3.1. En cuanto a las conclusiones del modelo utillizado (el mejor de todos los probados)

- **ANOVA clásico**
  - El ANOVA inicial no cumplía del todo el supuesto de normalidad de los residuos.
  - La homogeneidad de varianzas sí se cumplía.
  - Una transformación Box-Cox mejoró los residuos, pero no fue la mejor solución final.
- **Modelos GLM**
  - Se probaron varios modelos con distintas distribuciones:
    - **Gaussiano:** no adecuado (residuos no bien ajustados).
    - **Poisson:** problemas de sobredispersión.
    - **Binomial negativa:** buen ajuste a los datos, con residuos adecuados y estabilidad.
    - **Beta y Gamma:** útiles como comparación, pero menos interpretables en este caso.
  - Por tanto, el **modelo binomial negativa** fue el mejor para modelar los conteos de insectos. Tiene sentido, ya que la distribución binomial negativa sirve para casos de conteo en los que la Poisson da problemas. También nótese que sus curvas son discretas y sus funciones de probabilidad tienen su moda/máximo ligeramente desplazado a la izquierda.

3.2. En cuanto a las conclusiones sobre el conteo de insectos (del boxplot)

1. **Control**
   - Tiene los valores de conteo más altos y variables (con varias réplicas por encima de 100 y un máximo de 141).
   - Los tests de comparación múltiple le asignan la letra **b** (en el boxplot), lo que indica que **se diferencia significativamente de A+B** y en parte de A.
2. **Tratamiento A**
   - Generalmente bajos (muchas réplicas entre 6–27 insectos), aunque con un par de valores atípicos (69 y 134).
   - En el boxplot figura como **ab**, lo que significa que **no se diferencia significativamente ni de Control ni de A+B**, pero sí tiende a mostrar menores conteos que el control.
3. **Tratamiento B**
   - Tiene gran variabilidad, con réplicas bajas (8–38) pero también picos altos (96 y 292).
   - En el análisis se agrupa con la letra **b**, mostrando conteos similares al **Control**, y significativamente distintos de A+B.
4. **Tratamiento A+B (combinado)**
   - Es el que muestra los valores más bajos en promedio (varias réplicas con 0–22).
   - Se ubica en la categoría **a**, lo que confirma que **reduce significativamente los conteos frente al Control y B**, y se diferencia también de A en parte.
5. **Resumen:**
   - **El tratamiento más efectivo es la combinación A+B**, pues logra **la reducción más significativa en el número de insectos**.
   - **El Control y el Tratamiento B** se mantienen en el grupo con mayores conteos, sin diferencias significativas entre ellos.
   - **El Tratamiento A** queda en una posición intermedia: reduce insectos respecto a Control, pero no con la misma consistencia que A+B.